Informe de análisis y segmentación de clientes

Conjunto de datos Mall Customers (200 clientes) | 24 de octubre de 2026

1. Resumen ejecutivo

Los 200 clientes del centro comercial se agrupan en **cinco segmentos** definidos por ingreso anual y puntaje de gasto. El ingreso por sí solo no predice cuánto gasta un cliente (r = 0.01).

- **Datos limpios:** 200 registros, sin nulos ni duplicados, listos para modelar.
- **Edad:** es la única variable relacionada con el gasto (r = -0.33): los clientes más jóvenes gastan más.
- **Género:** no marca diferencias relevantes (gasto medio de 51.5 en mujeres y 48.5 en hombres, p = 0.42).
- **Segmentación:** K-means con k = 5 (silueta 0.555), con resultados estables entre ejecuciones.
- **Mayor oportunidad:** los 35 clientes del segmento Conservadores (17.5 %) tienen ingreso alto (88 k$) pero gastan solo 17 puntos en promedio.

2. Datos y metodología

El archivo *Mall_Customers.csv* contiene 200 clientes. No presenta valores nulos, filas duplicadas ni identificadores repetidos.

Variable	Tipo	Rango / distribución
Género	Categórica	112 mujeres (56 %), 88 hombres (44 %)
Edad (años)	Numérica	18 a 70
Ingreso anual (k$)	Numérica	15 a 137
Puntaje de gasto (1-100)	Numérica	1 a 99

Técnicas aplicadas:

- Estadísticos descriptivos, asimetría y detección de atípicos con el criterio del rango intercuartílico.
- Correlación de Pearson y pruebas t de Welch para comparar géneros.
- Segmentación con K-means sobre Ingreso y Gasto estandarizados, con 50 inicializaciones.
- Elección de k con el método del codo, el coeficiente de silueta y el índice de Davies-Bouldin.
- Estabilidad comprobada con 5 semillas aleatorias (ARI = 1.0 en todas).

3. Análisis exploratorio

3.1 Estadísticos descriptivos

Variable	Media	Mediana	Desv. est.	Mín	Máx	Asimetría	Atípicos
Edad	38.9	36	14.0	18	70	0.49	0
Ingreso anual (k$)	60.6	61.5	26.3	15	137	0.32	2 (137 k$)
Puntaje de gasto	50.2	50	25.8	1	99	-0.05	0

La edad tiene una ligera cola hacia las edades altas. El ingreso es casi simétrico y sus dos atípicos (137 k$) son datos reales, no errores. El puntaje de gasto es muy simétrico y está repartido a lo largo de toda la escala.

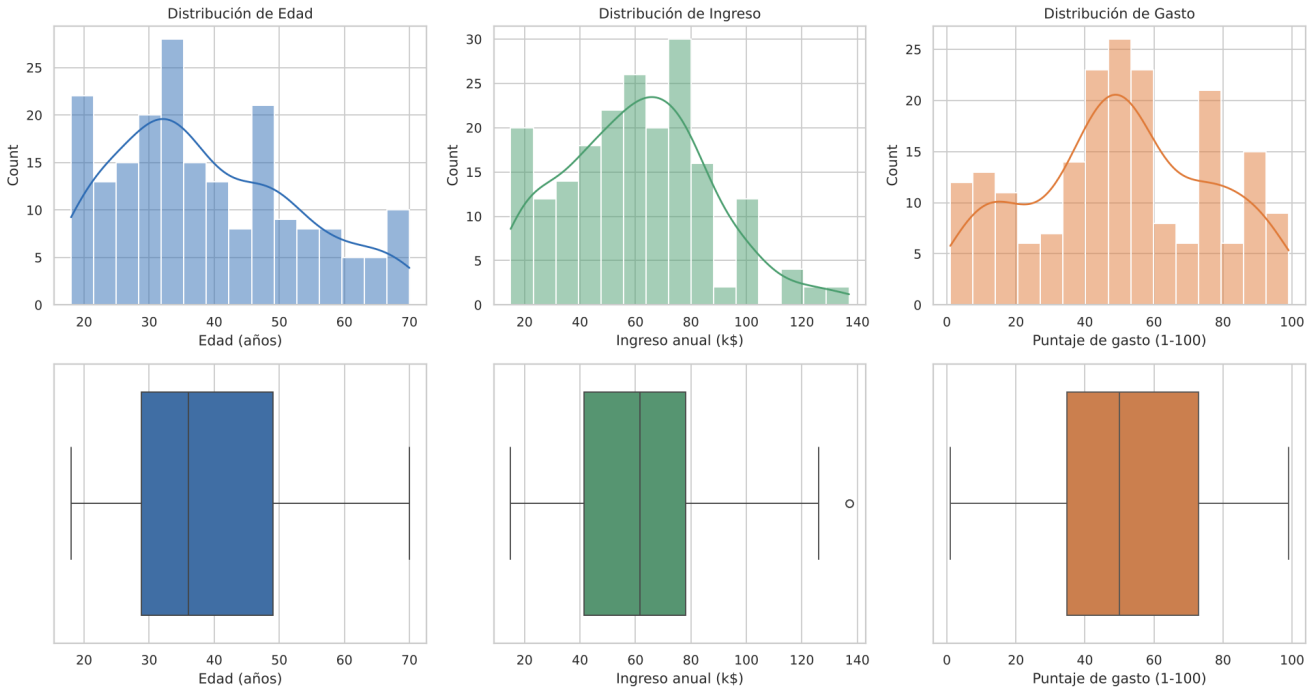


Figura 1. Histogramas y diagramas de caja de Edad, Ingreso y Gasto.

3.2 Diferencias por género

Las diferencias entre mujeres y hombres son pequeñas y no significativas: gasto medio de 51.5 contra 48.5 (p = 0.42), ingreso medio de 59.3 contra 62.2 (p = 0.43) y edad media de 38.1 contra 39.8. El género no explica el comportamiento de gasto.

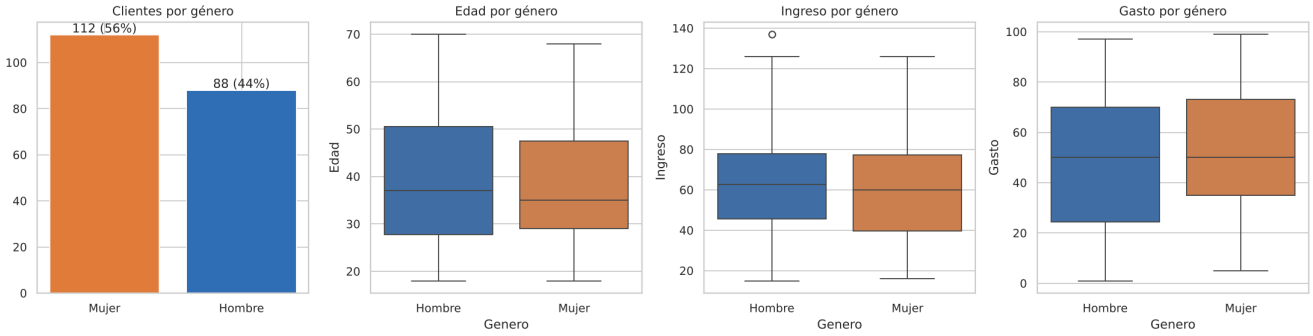


Figura 2. Composición por género y comparación de las tres variables numéricas.

3.3 Relaciones entre variables

Par de variables	Correlación (r)	Lectura
Edad y Gasto	-0.33	Negativa moderada y significativa: a mayor edad, menor gasto
Ingreso y Gasto	0.01	Prácticamente nula
Edad e Ingreso	-0.01	Sin relación

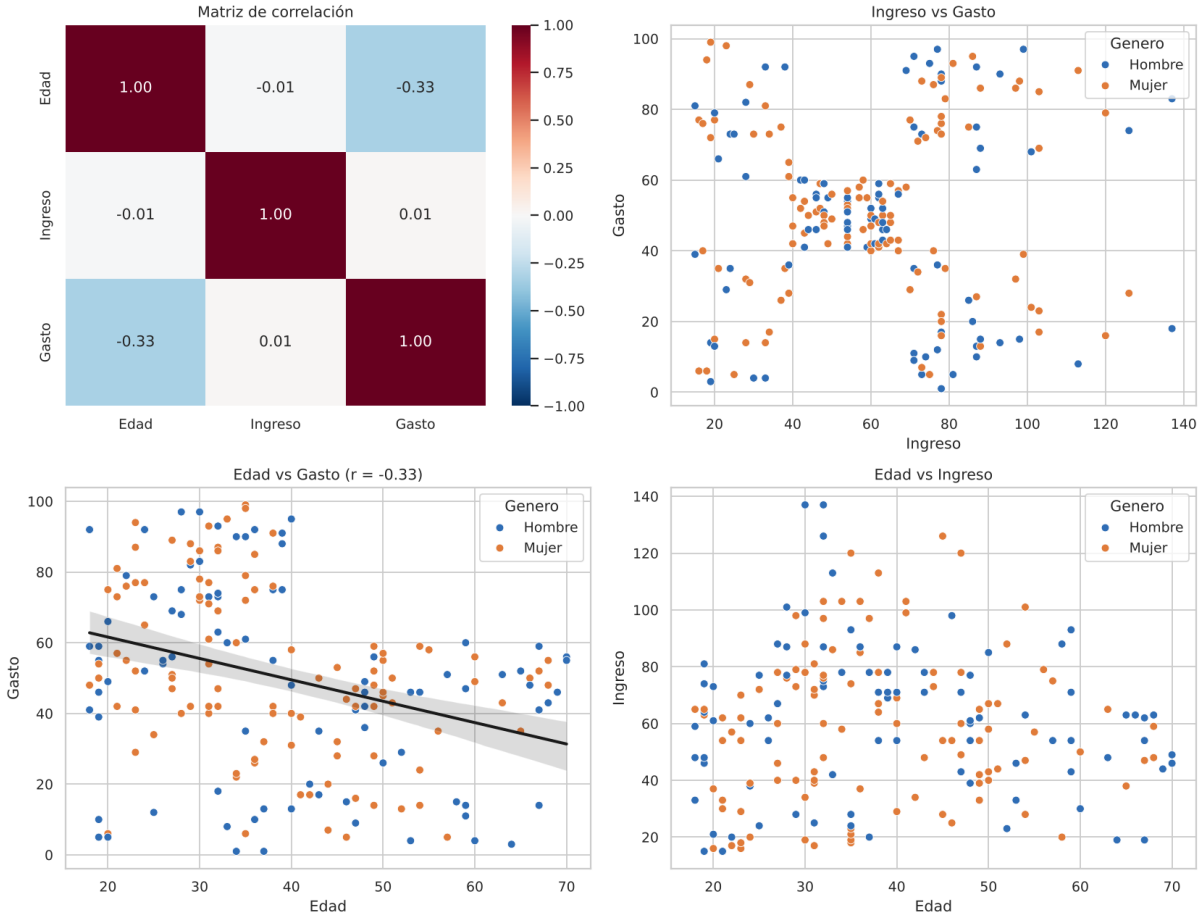


Figura 3. Matriz de correlación y diagramas de dispersión. En Ingreso vs Gasto se aprecian bloques bien separados que la correlación lineal no captura.

3.4 Grupos de edad

Grupo de edad	Clientes	Ingreso medio (k$)	Gasto medio
18-25	38	45.7	54.9
26-35	60	68.2	**64.4**
36-45	36	72.1	44.8
46-55	37	57.7	36.7
56 o más	29	53.7	38.4

El grupo de 26 a 35 años es el más numeroso y el de mayor gasto. A partir de los 36 años el gasto baja aunque el ingreso siga alto.

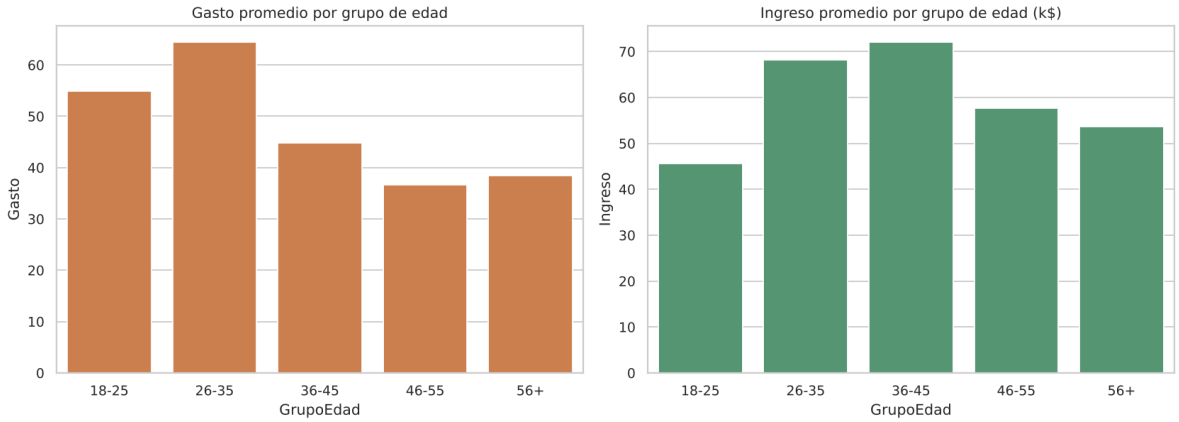


Figura 4. Gasto e ingreso promedio por grupo de edad.

3.5 Hallazgo principal: estructura en bloques

El gráfico de Ingreso vs Gasto no muestra una nube dispersa sino cinco bloques separados. En el rango de ingreso medio (40-70 k$) el gasto casi no varía (desviación de 8.5), mientras que en los ingresos bajos y altos varía mucho (desviación de 30 a 34). Por eso la correlación lineal es cercana a cero aunque exista una estructura clara.

4. Segmentación con K-means

Se aplicó K-means sobre Ingreso y Gasto estandarizados. Se eligió **k = 5** porque obtiene la mejor silueta, el mejor índice de Davies-Bouldin y es donde la inercia deja de bajar de forma marcada.

k	Inercia	Silueta	Davies-Bouldin
2	269.7	0.321	1.267
3	157.7	0.467	0.716
4	108.9	0.494	0.710
5	**65.6**	**0.555**	**0.572**
6	55.1	0.540	0.655
7	44.9	0.528	0.715
8	37.1	0.457	0.758
9	32.4	0.457	0.763
10	29.7	0.436	0.765

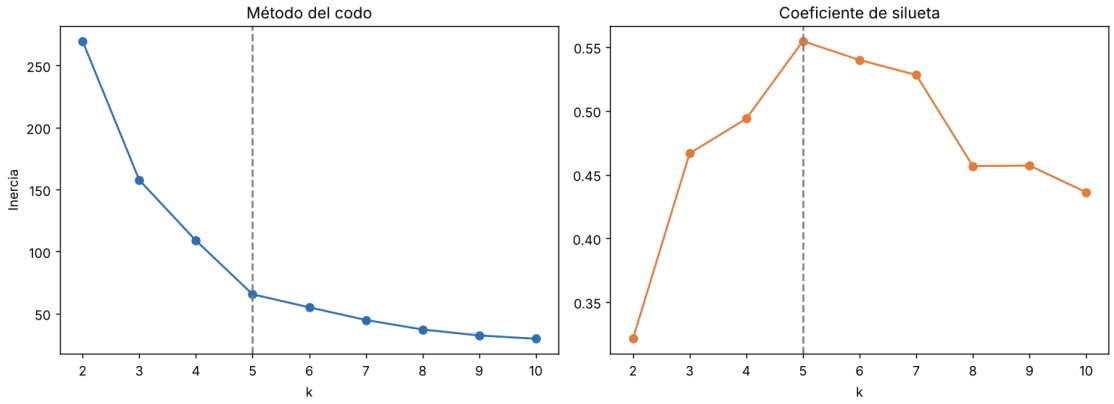


Figura 5. Método del codo y coeficiente de silueta para k de 2 a 10.

Al agregar la edad como tercera variable la silueta baja a 0.42, así que la estructura está en ingreso y gasto; la edad se usa solo para describir los grupos. Con 5 semillas aleatorias distintas se obtienen siempre los mismos grupos (ARI = 1.0).

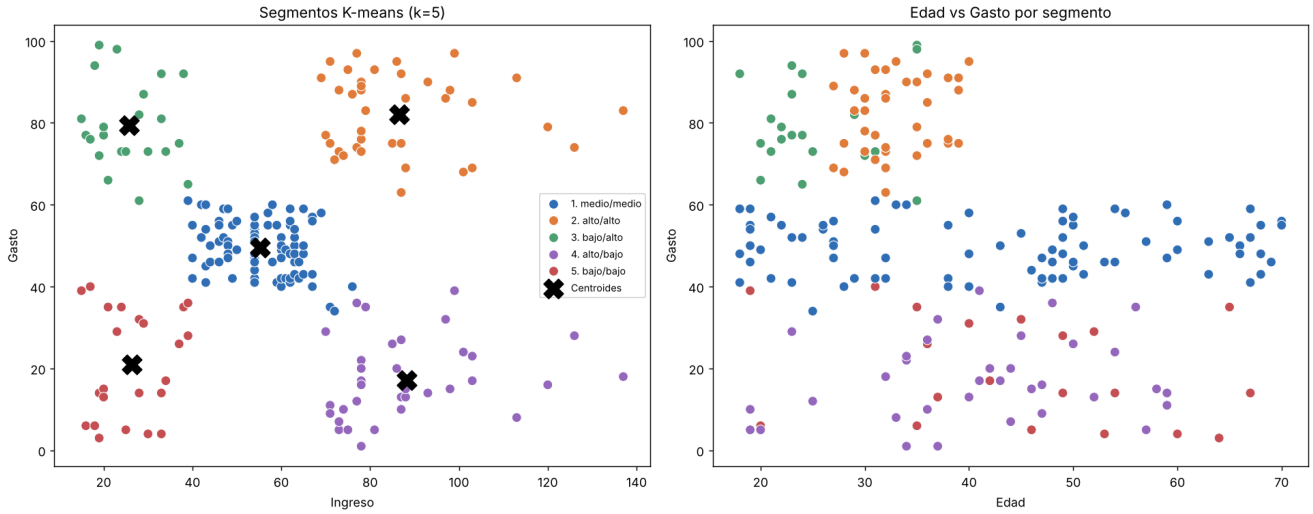


Figura 6. Segmentos obtenidos (izquierda) y su distribución por edad y gasto (derecha). Las X negras son los centroides.

5. Interpretación de los segmentos

Segmento	Clientes	Ingreso medio (k$)	Gasto medio	Edad media	% mujeres
Estándar (ingreso medio, gasto medio)	81 (40.5 %)	55.3	49.5	42.7	59 %
Premium (ingreso alto, gasto alto)	39 (19.5 %)	86.5	82.1	32.7	54 %
Jóvenes impulsivos (ingreso bajo, gasto alto)	22 (11 %)	25.7	79.4	25.3	59 %
Conservadores (ingreso alto, gasto bajo)	35 (17.5 %)	88.2	17.1	41.1	46 %
Austeros (ingreso bajo, gasto bajo)	23 (11.5 %)	26.3	20.9	45.2	61 %

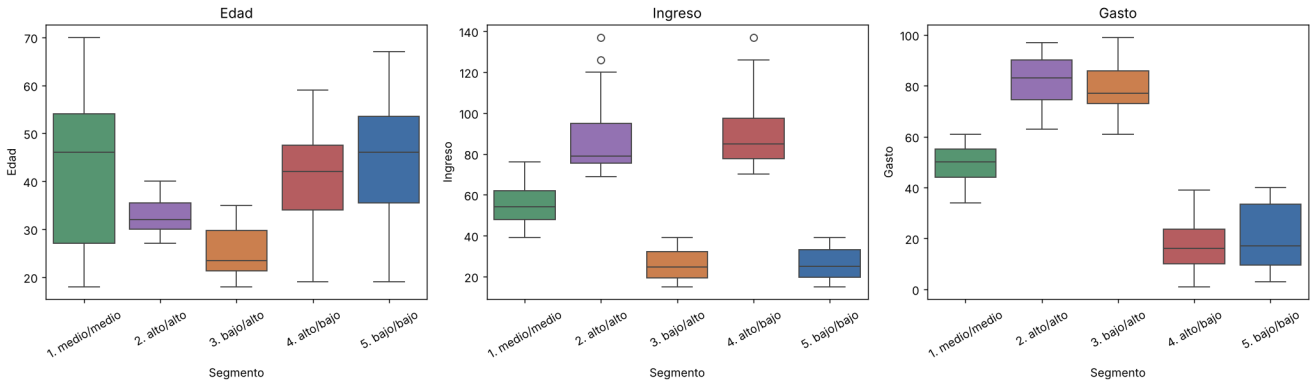


Figura 7. Edad, ingreso y gasto por segmento. Los segmentos se numeran 1 a 5 según el orden del algoritmo.

Estándar. Ingreso y gasto moderados, con la mayor dispersión de edades (18 a 70) y una edad media de 43. Es la base estable del centro comercial: hay poco que ganar con acciones agresivas, pero perderlos pesaría mucho por su volumen.

Premium. Alto poder adquisitivo y alto gasto, con edades de 27 a 40 años (media de 33). Son los mejores clientes.

Jóvenes impulsivos. Ingreso bajo (menos de 40 k$) pero gasto muy alto. Son los más jóvenes (media de 25 años) y gastan por encima de lo que ganan, probablemente por moda y experiencias. Su gasto puede ser inestable.

Conservadores. Ingreso alto y gasto muy bajo, de mediana edad. Tienen dinero y no lo gastan aquí, por lo que son el mayor potencial sin explotar.

Austeros. Ingreso y gasto bajos, con la edad media más alta (45). Su gasto es coherente con sus recursos y son los de menor prioridad comercial.

Hallazgos transversales:

- Premium y Jóvenes impulsivos suman el 30 % de los clientes y gastan casi igual (82 y 79) con ingresos muy distintos: el ingreso no determina el gasto.
- La edad separa bien los grupos de gasto alto: ambos tienen menos de 40 años casi sin excepción.
- El género no distingue ningún segmento: todos están entre 46 % y 61 % de mujeres.

6. Recomendaciones por segmento

Segmento	Objetivo	Acciones sugeridas
Premium	Fidelizar	Programa VIP, lanzamientos exclusivos, atención personalizada
Conservadores	Activar el gasto	Encuesta para entender por qué no compran aquí; oferta de gama alta y servicios; comunicación dirigida
Jóvenes impulsivos	Aprovechar sin sobreexponer	Promociones de temporada, cuotas y experiencias; vigilar la estabilidad de su gasto
Estándar	Mantener	Beneficios de recurrencia y comunicación general; evitar descuentos que erosionen margen
Austeros	Eficiencia	Descuentos y precios accesibles con bajo costo de contacto

7. Limitaciones y próximos pasos

- La muestra es pequeña (200 clientes): los segmentos más chicos (22 y 23 clientes) son menos robustos.
- Las etiquetas y las hipótesis de comportamiento son interpretaciones; los datos solo contienen ingreso, gasto, edad y género, no los motivos de compra.
- El puntaje de gasto es un índice (1-100) y no un monto, por lo que no permite estimar ingresos en dinero.
- Próximos pasos: contrastar con otros algoritmos (jerárquico, DBSCAN), validar los segmentos con información de compras reales y medir el efecto de las acciones por segmento.