INFORME DE ANÁLISIS Y SEGMENTACIÓN DE CLIENTES

Dataset: Mall_Customers.csv | Aprendizaje no supervisado con K-Means

Objetivo

Analizar las características de los clientes de un centro comercial, aplicar un algoritmo de segmentación no supervisada e interpretar los grupos obtenidos para proponer acciones de negocio.

Resumen ejecutivo

Se evaluaron agrupamientos de 2 a 8 grupos con las variables ingreso anual y puntuación de gasto. La solución de cinco segmentos obtuvo un coeficiente de silueta aproximado de 0,555 y permitió distinguir cinco perfiles interpretables: clientes con ingresos y gasto intermedios; clientes con ingresos altos y gasto elevado; clientes con ingresos bajos y gasto elevado; clientes con ingresos altos y gasto bajo; y clientes con ingresos y gasto bajos. Se proponen acciones comerciales distintas para cada perfil. Los resultados describen esta muestra y deben validarse con datos de ventas reales antes de tomar decisiones de inversión.

Octubre de 2026

1. Datos y metodología

El archivo contiene 200 clientes y cinco variables: CustomerID, Gender, Age, Annual Income (k$) y Spending Score (1-100). CustomerID se utiliza únicamente como identificador. Para el modelo inicial se seleccionaron Annual Income (k$) y Spending Score (1-100), de modo que los grupos reflejen la relación entre nivel de ingresos y puntuación de gasto. Gender y Age se reservaron para la caracterización posterior de los segmentos.

Preparación y algoritmo

Se estandarizaron las dos variables con StandardScaler y se evaluaron soluciones de K-Means para K entre 2 y 8. La solución reportada utiliza K=5, random_state=42 y n_init=20. La selección se apoyó en el método del codo y el coeficiente de silueta. La estandarización es importante porque K-Means utiliza distancias y las variables originales tienen escalas distintas.

2. Análisis exploratorio resumido

La base presenta 200 registros, cinco variables, 200 identificadores únicos, sin valores ausentes ni filas duplicadas reportadas en el análisis previo. La distribución por género es de 112 mujeres (56 %) y 88 hombres (44 %).

Estadístico	Edad	Ingreso anual (miles USD)	Puntuación de gasto
Media	38,85	60,56	50,20
Mediana	36,00	61,50	50,00
Desviación estándar	13,97	26,26	25,82
Mínimo	18	15	1
Máximo	70	137	99

La correlación de Pearson entre edad e ingreso es -0,012; entre edad y puntuación de gasto, -0,327; y entre ingreso y puntuación de gasto, 0,010. Esto indica que, en la muestra completa, el ingreso no presenta una relación lineal apreciable con la puntuación de gasto. La asociación negativa entre edad y puntuación de gasto es moderada y descriptiva; no implica causalidad.

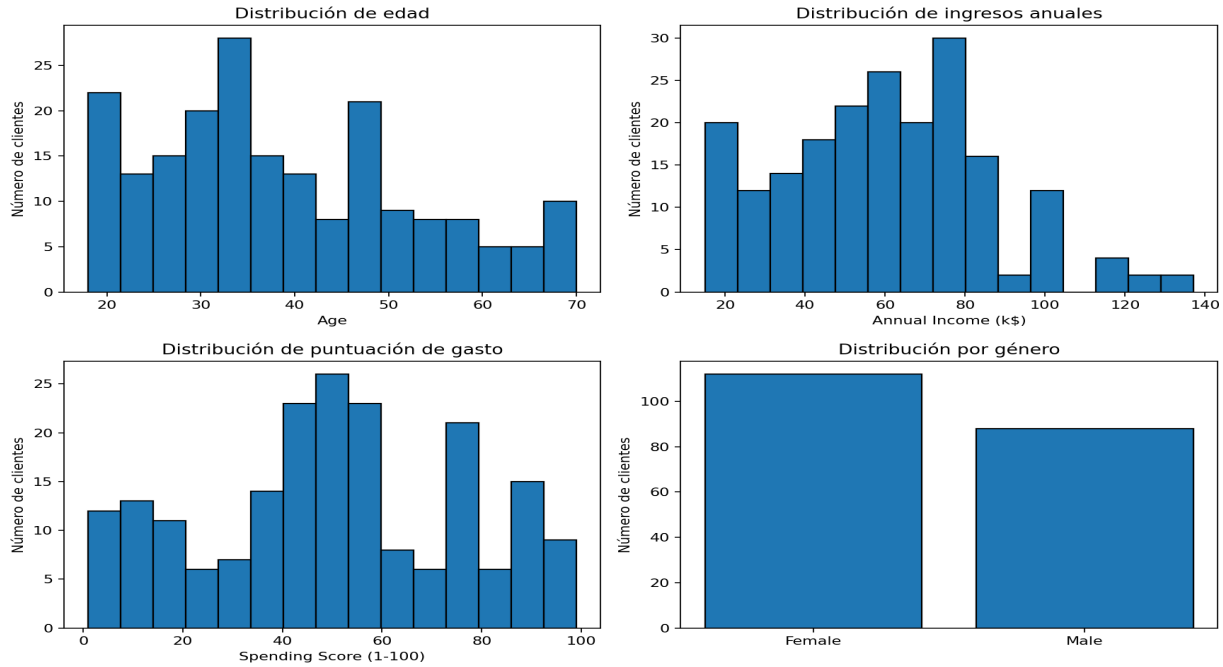


Figura 1. Distribuciones exploratorias del dataset.

3. Selección del número de grupos

K	Inercia	Silueta
2	269,69	0,321
3	157,70	0,467
4	108,92	0,494
5	65,57	0,555
6	55,06	0,540
7	44,86	0,528
8	37,15	0,457

Entre las alternativas evaluadas, K=5 obtuvo la silueta más alta (aproximadamente 0,555). La inercia también disminuye al aumentar K, como es esperado; por eso no debe usarse por sí sola para seleccionar el número de grupos. La solución de cinco segmentos es razonable y manejable para interpretación de negocio, pero la elección depende también de los objetivos comerciales.

4. Segmentos identificados

Segmento	Clientes	%	Edad media	Ingreso medio (miles USD)	Gasto medio
0 · Intermedios	81	40,5 %	42,72	55,30	49,52
1 · Alto ingreso / gasto alto	39	19,5 %	32,69	86,54	82,13
2 · Bajo ingreso / gasto alto	22	11,0 %	25,27	25,73	79,36
3 · Alto ingreso / gasto bajo	35	17,5 %	41,11	88,20	17,11
4 · Bajo ingreso / gasto bajo	23	11,5 %	45,22	26,30	20,91

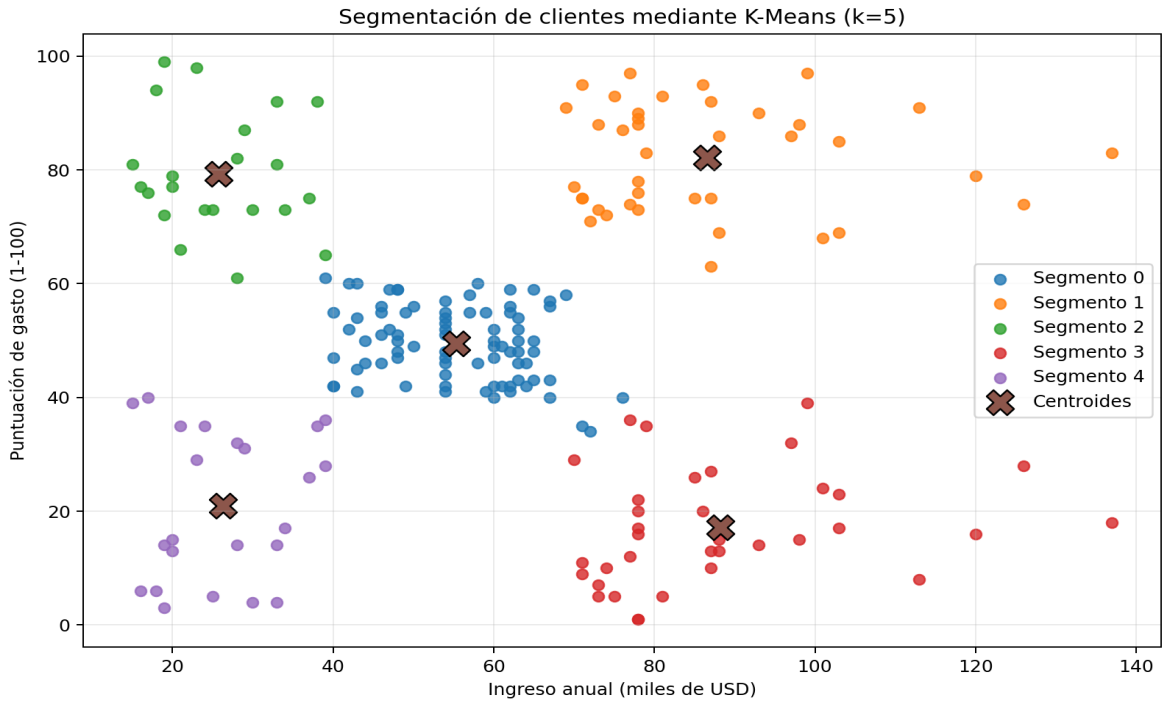


Figura 2. Segmentos en el espacio de ingreso anual y puntuación de gasto; las cruces representan centroides.

5. Interpretación de los segmentos

Segmento 0 — Ingresos y gasto intermedios

Es el grupo más numeroso (81 clientes; 40,5 %). Presenta ingreso medio de 55.300 USD y puntuación de gasto de 49,52. Puede ser una base adecuada para fidelización y para probar recomendaciones complementarias. Por su tamaño, pequeños cambios de comportamiento podrían tener relevancia, aunque el efecto debe medirse.

Segmento 1 — Ingresos altos y gasto elevado

Agrupa 39 clientes (19,5 %), con ingreso medio de 86.540 USD y gasto medio de 82,13. Es un grupo de alto potencial comercial. Se recomienda proteger la relación mediante beneficios exclusivos y experiencias relevantes, sin asumir que la puntuación equivale a rentabilidad real.

Segmento 2 — Ingresos bajos y gasto elevado

Incluye 22 clientes (11 %), con ingreso medio de 25.730 USD y gasto medio de 79,36. Su perfil muestra que el ingreso no basta para explicar la puntuación de gasto. Se podrían probar promociones pertinentes y programas de recurrencia, controlando el margen y la respuesta real.

Segmento 3 — Ingresos altos y gasto bajo

Incluye 35 clientes (17,5 %). Tiene el ingreso medio más alto (88.200 USD) y la puntuación de gasto más baja (17,11). Puede ser prioritario para investigar barreras de compra y probar campañas de activación. El dataset no permite confirmar si visitan poco, compran en otros establecimientos o responden a promociones.

Segmento 4 — Ingresos bajos y gasto bajo

Incluye 23 clientes (11,5 %), con ingreso medio de 26.300 USD y gasto medio de 20,91. Se recomiendan acciones de bajo costo, ofertas selectivas y comunicaciones relevantes. La prioridad de inversión debe depender de la conversión y del margen incremental.

6. Plan de acción e indicadores

Segmento	Acción recomendada	Indicadores sugeridos
0	Programa de puntos y recomendaciones complementarias.	Frecuencia de compra; gasto real por cliente.
1	Beneficios exclusivos y fidelización personalizada.	Retención; valor y margen por cliente.
2	Promociones relevantes y beneficios por recurrencia.	Recompra; respuesta a promociones; margen.
3	Campañas de activación y pruebas controladas.	Conversión incremental; gasto real; costo de campaña.
4	Ofertas selectivas y comunicaciones de bajo costo.	Conversión; costo por cliente; margen incremental.

Se recomienda probar las acciones mediante campañas piloto y, cuando sea posible, grupos de control. Los resultados deben medirse con compras observadas, margen y costos de campaña, no únicamente con la puntuación de gasto del dataset.

7. Limitaciones y recomendaciones

• La base contiene solo 200 clientes; los patrones no necesariamente se generalizan a otros centros comerciales.

• Spending Score es una puntuación asignada y no representa directamente ventas, frecuencia de compra o margen.

• No se dispone de historial transaccional, productos adquiridos, costos de campaña ni rentabilidad individual.

• K-Means es sensible a valores extremos, a la escala de las variables y a la selección de K.

• Las etiquetas de los segmentos son descriptivas; los números 0 a 4 son identificadores arbitrarios del modelo.

Recomendaciones para continuar

• Validar la estabilidad de los segmentos con distintas semillas y, si se dispone, con datos de otros períodos.

• Comparar el modelo de dos variables con otro que incorpore edad, comprobando si mejora la utilidad empresarial.

• Enriquecer el análisis con transacciones reales y métricas RFM: recencia, frecuencia y valor monetario.

• Evaluar campañas con indicadores de conversión incremental, retención, margen y costo de adquisición o reactivación.

8. Conclusión

K-Means permitió identificar cinco perfiles diferenciados de clientes a partir de sus ingresos y puntuación de gasto. La solución con cinco grupos obtuvo la mejor silueta entre K=2 y K=8 (0,555) en la evaluación reportada. Los perfiles sugieren oportunidades distintas: fidelizar clientes de alto gasto, activar a clientes con ingresos altos y puntuación baja, y aplicar estrategias de costo controlado en otros grupos. La segmentación debe considerarse una herramienta de apoyo a la decisión, no una prueba de causalidad ni una medida directa de rentabilidad. Las acciones propuestas requieren validación con datos comerciales reales.